

LSTM モデルを用いた無線リンク品質推定

関東悠樹[†] 渡部康平[†]

[†] 長岡技術科学大学 大学院工学研究科
〒940-2188 新潟県長岡市上富岡町 1603-1

E-mail: [†]s213121@stn.nagaokaut.ac.jp, [†]k.watabe@vos.nagaokaut.ac.jp

あらまし 近年、移動体通信デバイスでは高速で大容量なワイヤレスネットワークを介して様々なサービスが提供されており、屋内外、環境を問わず安定して通信を行なうことが求められている。本研究では、シーケンシャルな情報を活用することで、ワイヤレスネットワークの接続品質を推定するための新しい WLQE モデルを提案する。提案手法は LSTM を基にした LSTM-based LQE であり、Accuracy 及び macro-F1 による評価で、従来手法の SAE-LQE と比較して Accuracy は 4.0%、macro-F1 は 4.6% も高精度にリンク品質推定を行えることを確認した。

キーワード ワイヤレスネットワーク、リンク品質推定、機械学習、LSTM

Analysis of Wireless Link for Mobile Communication Devices Using a Machine Learning Model

Yuki KANTO[†] and Kohei WATABE[†]

[†] Graduate School of Engineering, Nagaoka University of Technology
1603-1 Kamitomioka, Nagaoka, Niigata, 940-2188 Japan

E-mail: [†]s213121@stn.nagaokaut.ac.jp, [†]k.watabe@vos.nagaokaut.ac.jp

Abstract In recent years, mobile communication devices have been providing various services via high-speed and high-capacity wireless networks, and stable communication is required regardless of indoor or outdoor environments. In this study, we propose a new WLQE model to estimate the connection quality of wireless networks by utilizing sequential information. The proposed method is an LSTM-based LQE, and the accuracy and macro-F1 evaluations show that the proposed method can estimate the link quality more accurately than the conventional method, SAE-LQE, by 4.0% and 4.6%, respectively.

Key words Wireless Networks, Link Quality Estimation, Machine Learning, LSTM

1. はじめに

近年、移動体通信デバイスは高速で大容量なワイヤレスネットワークを介して様々なサービスが提供されており、屋内外、環境を問わず安定して通信を行なうことが求められている。この移動体通信デバイスとは、スマートフォン、autonomous mobility, Unmanned Aerial Vehicle (UAV), IoT 機器など多様なデバイスを含んでおり、サービス形態によってはネットワーク接続が運用上必要不可欠な場合もある。無線ネットワークの接続に対する依存度が高いサービスの場合、リンク品質の安定性と信頼性はサービスの品質を維持する上で最も重要なファクターである。

安定した通信環境を提供するためには、通信が不安定になる前に最適な通信経路へ変更したり、データのバッファ確保を行うなどの対応が有効であり、現在や未来のワイヤレスネットワークの接続品質を推定する Wireless Link Quality Estimation

(WLQE) の技術が重要である。WLQE により無線ネットワークの品質を定量的に評価することで、リアルタイムあるいは anticipatory にネットワークの最適化に必要な処理を行うことが可能です。これにより、安定した通信環境のもと、モバイルデバイスを通して提供するサービスの品質が安定し、高いユーザーエクスペリエンスと安全なデバイス運用が実現する。

近年は、統計的手法に代わって機械学習の手法を用いた WLQE が盛んに研究されてきているが、リンク品質のデータのシーケンス、すなわち時系列的な情報の活用はほとんど検討されていない。機械学習の手法を活用した多くの WLQE 手法が報告されており、ランダムフォレスト、ロジスティック回帰、人工ニューラルネットワーク (ANN) などを使った手法 [1] が提案されてきた。深層学習を用いた SAE-LQE モデル [2] は state-of-the-art の WLQE 手法の一つだが、入力データとしてシーケンシャルデータを採用しておらず、時間とともに動的に変化するリンク

品質の特性を十分に活用できていない。

本論文では、Long Short-Term Memory (LSTM) によりシーケンシャルな情報を活用して、未来のリンク品質を正確に推定する LSTM-based LQE モデルを提案する。LSTM-based LQE モデルは、過去のリンク品質に関するメトリクスをシーケンスデータとして LSTM により処理し、ビンニング法による離散化で未来のリンク品質のグレードを出力する。LSTM により、シーケンスデータ内の潜在的なパターンや時間的依存関係を含む特徴空間内のデータの分布をより良く捉えることができ、高精度に分類できることが期待される。提案手法の性能は、実環境のリンク品質を記録したデータセットを用いてベースラインモデルの SAE-LQE と比較評価を行う。

本稿の残りの部分は以下のように構成されている。セクション 2. では、WLQE 分野の関連研究について述べる。本論文で提案する手法に関して、セクション 3. で詳述する。続いてセクション 4. で提案手法とベースラインモデルの性能比較のための評価方法と結果について述べる。セクション 5. では、本論文の結論と今後の課題について述べる。

2. 関連研究

WLQE の研究は 1990 年代後半に始まり、統計的アプローチを中心に盛んに研究が行われてきた [1]。初期の LQE モデルは、無線伝送方式は有線伝送方式と比べて、パケット損失が大きくなりやすいことを示していた。1996 年に、統計的手法に基づいてパケットストリームのエラーとエラーのない長さの分布に基づいて TCP のスループットの向上に寄与するエラーモデル [3] が提案された。LQE に関する論文は、マルコフモデルをはじめとする統計モデル [3]~[7]、ルールや閾値に基づくモデル [8]~[10]、ファジー論理と機械学習を組み合わせたファジー ML モデル [11]~[14] などが提案されてきた。

2010 年以降、LQE の研究はナイーブベイズ分類器、ロジスティック回帰、ANN の機械学習的手法を用いて、Packet Reception Ratio (PRR), Received Signal Strength Indicator (RSSI), Signal-to-Noise Ratio (SNR) などのリンク品質のメトリクスに基づいて PRR を推定するモデルが提案された [15]。これらの研究が報告されて以来、機械学習的手法によるワイヤレスリンク品質推定モデルが注目され様々な機械学習的手法を用いた WLQE モデルが提案されている。代表的な機械学習的手法としては、ロジスティック回帰をはじめとする統計的 ML モデル [15]~[24]、強化学習モデル [25]、スタック型オートエンコーダーをはじめとする深層学習モデル [2]、[26] が挙げられる。

特に Deep Learning (DL) モデルに分類される LQE-SAE は、RSSI, SNR, LQI の 3 つの特徴量をそれぞれ Stacked AutoEncoder (SAE) に入力することで高精度にリンク品質グレードを推定するモデル [2] であり、最も優れた LQE 手法の一つである。機械学習の手法が用いられるようになった背景としては、統計的手法では限られたデータセットと特徴量を基にモデル化しているため、実環境への適応性や推定精度に限界があった。そのため、大規模なデータセットと SNR, RSSI を含む多くの特徴量を効率的に学習し、より高精度で適応性の高い機械学習

的手法を用いたモデルに焦点が当てられている。

3. 提案手法

我々は、従来の機械学習のモデルではシーケンシャルな情報を活用できていないと考え、シーケンシャルな情報を活用できる LSTM ベースの WLQE モデルを用いて、高精度なリンク品質推定を可能にするモデルと学習方法を提案する。提案するモデルは、LSTM でリンク品質のメトリクスである RSRP を回帰モデルとして予測し、その後ビンニング法を用いたマルチクラス分類により、リンク品質を 5 段階のグレード（非常に良い、良い、普通、悪い、非常に悪い）に分類される。LSTM には、RSRP を含むリンク品質のメトリクスが時系列に並んだシーケンスを特徴量として入力している。一方、モデルの出力は LSTM が予測した未来の時点の RSRP 値をビンニング法により離散化したリンク品質のグレードを表している。

3.1 前処理

提案手法では、継続的に観測した RSRP などのリンク品質メトリクスのデータセットをシーケンスデータとしてモデルに入力する前にデータセットを前処理する。すなわち、欠損値のインピュテーション、オーバーサンプリング、ノイズの分離、標準化、ビンニングの 5 つの前処理を行う。

欠損値補間と Over Sampling には、機械学習の分野で一般的に使用されている技術を採用した。データセットの欠損値補間には、ゼロパディングを採用している。ゼロパディングを採用する理由は、平均値補間や線形補間のような技法を使用する方法と比較して、この分野の既存の機械学習アプローチの性能を向上させることが観察されているからである [1]。さらに、リンク品質グレードのクラス間の分布のバランスをとるために、少数派クラスのデータに Rundum Over Sampling (ROS) を適用し、多数派クラスのサンプル数と一致させる。

RSRP のようなリンク品質メトリクスは、しばしば大きな変動を示し、ノイズの多いデータを含むため指数移動平均 (EMA) を使って、長期的なトレンド項とノイズ項に分離する。 j 番目の特徴量のシーケンス x_t^j ($t = 0, 1, 2, \dots$) に対するトレンド成分 \tilde{x}_t^j は、以下のように定義される。:

$$\tilde{x}_0^j = x_0^j, \quad (1)$$

$$\tilde{x}_t^j = \alpha x_t^j + (1 - \alpha) \tilde{x}_{t-1}^j, \quad (2)$$

ここで、 α は smoothing factor である。smoothing factor は、提案法のパラメータである span 係数 τ により

$$\alpha = \frac{2}{\tau + 1.0} \quad (3)$$

と定義される。

ノイズ成分 ε_t^j は、実測値 x_t^j とトレンド成分 \tilde{x}_t^j の差分であり、

$$\varepsilon_t^j = x_t^j - \tilde{x}_t^j \quad (4)$$

と定義される。

入力される各特徴量は、変化の大きさも、スケールも異なる

表 1 RSRP 値とリンク品質の対応

RSRP[dBm]	リンク品質グレード
$-84 \leq$	非常に良い
$-84 < \text{RSRP} < -95$	良い
$-95 < \text{RSRP} < -105$	普通
$-105 < \text{RSRP} < -115$	悪い
$\text{RSRP} \leq -115$	非常に悪い

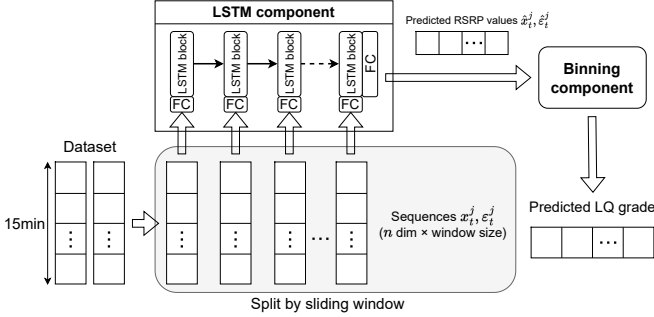


図 1 Model architecture

ため、平均を 0、分散を 1 にスケールする標準化を行い、各特徴量同士のスケールを均等化する。LSTM が出力する連続値の RSRP 推定値をマルチクラス分類するビンニング法は、表 1 の各リンク品質のビン幅に基づいて、RSRP の値をリンク品質グレードに離散化する。

3.2 モデルアーキテクチャ

提案手法のアーキテクチャは図 1 に示すように、LSTM のコンポーネントとビンニング処理のコンポーネントの 2 つのコンポーネントから構成される。LSTM コンポーネントは、データセットから取り出した長いシーケンスデータをスライディングウィンドウで分割し、RSRP を含む n 個の特徴量のトレンド成分とノイズ成分の長さ N のシーケンス $[\hat{x}_t^1, \hat{x}_t^2, \dots, \hat{x}_t^n, \varepsilon_t^1, \varepsilon_t^2, \dots, \varepsilon_t^n]^T$ ($t = 0, 1, 2, \dots, N-1$) を学習する。LSTM コンポーネントの出力は、1 タイムスロット先の RSRP の値 x_N^1 であり、未来の RSRP の値を予測する回帰モデルになっている。LSTM から出力される予測値はトレンドとノイズ成分の 2 種類であるため、後処理としてトレンドとノイズ成分を合算する $\hat{x}_t^n + \varepsilon_t^n$ 処理がある。この合算値が RSRP の予測値として次のコンポーネントの入力値となる。

一方、ビンニング処理のコンポーネントは LSTM から出力される RSRP 推定値から、ビン幅により連続値を離散化するビンニング法を用いてリンク品質グレードに分類する。LSTM モデルは、シーケンシャルなデータの処理に対して有効である一方、離散的なリンク品質グレードの推定は不得意であるため、ビンニング法による多クラス分類によりリンク品質のグレードを推定する。

本研究で回帰問題ではなく分類問題を採用した理由は、既存の手法が分類問題に基づいており、提案手法モデルと先行手法モデルとの直接的な比較を容易にするためである。

3.3 学習アルゴリズム

提案手法では、LSTM コンポーネントのパラメータをデータ

セットにより訓練して最適化する。LSTM コンポーネントの訓練では、まずセクション 3.1 に示した方法で前処理を行ったデータセットを、訓練と検証データセットに分割する。その後、分割したデータセットをスライディングウィンドウを用いて、長さがウィンドウサイズ N のシーケンスとなる入力データを作成する。さらにその入力データの次のタイムスロットの RSRP 値からラベルデータを作成する。訓練データセットで学習を進め、学習過程において検証データセットでの損失関数の値が最小となるように進めていくが、損失関数の値に改善が見られなくなった際に Early Stopping によって早期終了する。早期終了後、検証データの損失関数が最小の時を訓練済みモデルとして選択する。この損失関数は、 i 番目の入力データに対する RSRP の推定値 \hat{x}_i とラベルデータ x_i との平均二乗誤差 (MSE) であり、以下の式で定義される。

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{x}_i - x_i)^2. \quad (5)$$

4. 実験結果

我々は、提案した LSTM ベースの LQE モデルを実際の移動体通信デバイスで記録したデータセットを用いて学習と推定を行う。ベースラインモデルの SAE-LQE と比較するため、同じデータセットを用いて学習と予測を行い、Accuracy 及び F1 score による性能比較を行う。評価を通して、LSTM-based LQE がベースラインモデルの SAE-LQE よりも優れた性能であることを示す。

4.1 データセット

本研究で用いたデータセットは、“LTE-4G-HIGHWAY-DRIVE-TESTS-SALZBURG” という、Salzburg Research Forschungsgesellschaft (SRFG) から提供されているオーストリアで計測された実環境でモバイル端末の通信品質を記録したデータセット [4] である。オーストリアの一般的な高速道路区間を 2018 年から 2019 年まで 2 年間にわたって、繰り返し実施した車を用いた走行テストによるアクティブな 4G LTE 測定データセットである。本データセットには、1 秒毎の信号レベル、受信信号強度 (RSSI)、信号対干渉雑音比 (SINR)、基準信号受信電力 (RSRP)、基準信号受信品質 (RSRQ) などの通信メトリクス、および瞬時データレートを含む合計 267,198 個の測定データが含まれている。実際の環境で 4G LTE モバイル通信を分析、研究するための包括的かつ詳細なリソースを研究者に提供するために作成された。データセットに含まれる RSRP と SINR のサンプルを図 2 に示す。本データセットは、開始地点から終了地点までの約 25km の一連の移動をセッションというまとまりで記録している。本論文では、このデータセットから基準信号受信電力 (RSRP)、信号対干渉雑音比 (SINR) を用いている。

4.2 先行研究

提案手法の LSTM-based LQE モデルの実環境データセットでの推定精度を評価するため、LSTM-based LQE の性能をベースラインモデル:SAE-LQE [2] と比較する。最新の機械学習的手法を用いた LQE モデルである SAE-LQE モデルは、既存の LQE 手法の中で最も高精度なリンク品質推定モデルのため、ベースラ

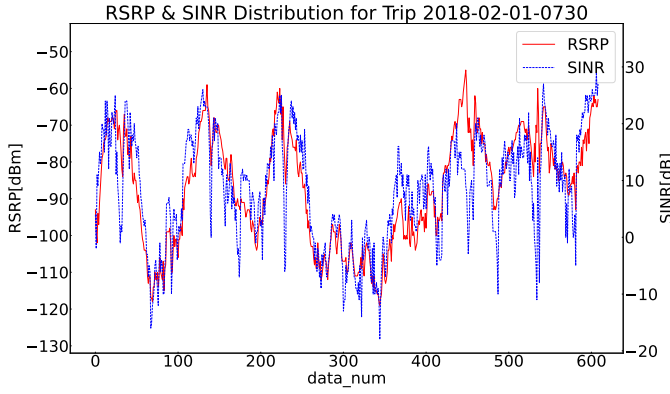


図2 データセット内のサンプルのRSSIとSINRの時系列変化。本サンプルのRSRPの平均は -87.17dBm (標準偏差: 14.94dBm), SINRの平均は 8.62dB (標準偏差: 9.67dB)である。

インとして利用する。SAE-LQEモデルは、Stacked AutoEncoder (SAE)をベースにRSRP, SINRの2つの特徴量をそれぞれSAEにアップリンク、ダウンリンクを入力し、特徴量を圧縮する。その2基のSAEで圧縮した特徴量をさらにSAEに入力し圧縮し、SVCで多クラス分類を行いリンク品質グレードを推定する。今回は使用するデータセットに含まれる特徴量が限られているため、RSRP, SINRの2つの特徴量によるSAE-LQEモデルをベースラインモデルとした。評価では、論文[2]に基づいたハイパーパラメータを設定したモデルを使用する。

4.3 パラメータ設定

提案モデル及びベースラインモデルは、Pytorchフレームワークで実装されており、それに基づいてパラメータの設定を行う。LSTM-based LQEのハイパーパラメータは以下のように設定される。前処理のEMAのspan係数 τ は120、スライディングウィンドウのウィンドウサイズ N は370である。LSTMのコンポーネントでは、LSTM層は2層、隠れ層のユニット数は128、最適化関数はAdam、学習率は0.001、バッチサイズは128、エポック数は1000、ドロップアウト率は0.266を使用する。LSTM学習では、Early Stoppingを有効にし、patienceとdelta parametersはそれぞれ50と -0.0001 として学習を終了している。ビン処理のコンポーネントにおける、ビン幅は表1に示すように設定されている。ビン幅は、Inseego Corporationによって公開されているMiFi RSRP品質定義に基づいて設定されている[27]。

SAE-LQEのハイパーパラメータは以下のように設定される。SAE-LQEは、論文[2]で採用されているハイパーパラメータ値が設定されているが、SAE-LQEのアーキテクチャの1段目に位置するSAEはRSRP, SINRのみの特徴圧縮を行うため、3基ではなく2基のSAEを用いている。また、使用するデータセットにはダウンリンク情報の通信メトリクスのみしか記録されていないため、存在しないアップリンク情報についてはセクション3.1に基づいて、ゼロパディングされている。リンク品質の正解ラベルの定義については、LSTM-based LQEと同様に表1に示すビン幅に基づいて、5クラスが設定されている。

4.4 評価指標

精度の評価は、多クラス分類の評価指標であるAccuracy及びmacro-F1を用いて評価を行う。データセット内のクラスの分布が均等でないため、Accuracyは全体的な正確性を示す一方で、macro-F1は各クラスごとの性能を均等に評価するため、Accuracyとmacro-F1を併用することで、モデルの性能をより包括的に評価できる。したがって、モデルがすべてのクラスに対して適切に動作し、クラスの不均衡に対処できることを確認するのに役立つため、本論文では2種類の評価指標をモデルの性能として利用する。また、クラス毎の性能の評価にはAccuracyとRecallによって解析する。

まず、多クラス分類の評価指標を算出する際に使用される値、真陽性 (TP)、偽陽性 (FP)、真陰性 (TN)、偽陰性 (FN) は以下のように定義される。

- True Positives (TP) とは、正しいクラスに正しく分類されたサンプル数であり、すなわちモデルがクラス A をクラス A と正確に予測した数である。
- False Positives (FP) とは、誤ってクラス A と予測されたが、実際はクラス A ではないサンプル数である。
- True Negatives (TN) とは、正しいクラス以外に正しく分類されたサンプル数であり、すなわちモデルがクラス B 以外をクラス B 以外と正確に予測した数である。
- False Negatives (FN) とは、誤ってクラス B 以外と予測されたが、実際はクラス B ではないサンプル数である。

Accuracyとは、正しく分類されたサンプルの割合を示す指標であり、以下の式で定義される。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \quad (6)$$

ここで、TP, TN, FP, FN はそれぞれ、True Positives, True Negatives, False Positives, False Negatives のサンプル数を表す。Accuracy は、モデルがすべてのクラスで正確に予測した割合を示し、すべてのクラスを同等に扱い全体的な正確さを評価し、値が高いほどモデルの正確性が高いことを示す。

macro-F1 は、以下の式に示すように、各クラスの F1-score を総クラス数 n で割った平均であり、各クラスが均等に重要な場合に有用である。

$$macro-F1 = \frac{1}{n} \sum_{i=1}^n F1_i, \quad (7)$$

ここで、 $F1_i$ は i 番目のクラスの F1-score を表す。macro-F1 を使用することで、それぞれのクラスの性能を無視せずに総合的な性能を評価することが可能である。

macro-F1 は、各クラスごとに F1-score を計算し、それらの平均値を取ったものである。macro-F1 の値が高いほど、各クラスの性能が均等に高いことを示し、モデルの性能が高いことを示す。そのため、クラスの不均衡がある場合や特定のクラスの性能が重要な場合に有用である。macro-F1 で用いられる F1-score とは、適合率 (Precision) と再現率 (Recall) の調和平均であり、モデルの分類性能を総合的に評価する。

Precision は、Eq.(8) に示すようにクラス A と予測されたサン

表 2 Performance of the three models

Model	Accuracy[%]	macro-F1[%]
SAE-LQE	80.5	80.6
LSTM-based LQE	84.5	85.2

プルのうち、実際にクラス A であるサンプルの割合を示す。

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

Recall は、Eq.(9) に示すように実際にクラス A であるサンプルのうち、クラス A と予測されたサンプルの割合を示す。

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

F1-score は、Eq.(10) に示すように、Precision と Recall の調和平均であり、Precision と Recall のバランスを示す。

$$F1score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (10)$$

4.5 性能評価

このセクションでは、2つのモデルの性能をセクション 4.4 で定義した Accuracy と macro-F1 を用いて比較評価する。“SRFG”データセットに対する、推定結果の概要を表 2 に示す。表中で値が太字になっている箇所は、2つのモデルの中において最高パフォーマンスであることを示している。表 2 より、LSTM-based LQE が Accuracy, macro-F1 とともに最高の性能を示していることがわかり、従来の SAE-LQE を凌駕していることが確認できる。LSTM-based LQE は、SAE-LQE と比較して、Accuracy は +4.0%, macro-F1 は +4.6% 高い性能を示した。

また、各クラスごとの Accuracy と Recall のグラフを提案手法の LSTM-based LQE は図 3 に、先行手法である SAE-LQE は図 4 に示す。LSTM-based LQE について図 3 から、Accuracy がクラス 2(悪い), クラス 3(普通), クラス 4(良い), クラス 5(非常に良い)で 80% 以上であった。Recall については、クラス 1(非常に悪い)とクラス 5(非常に良い)で 90% 以上で、クラス 4(良い)で 80% 以上であることがわかる。これは、リンク品質が非常に悪い場合と非常に良い場合の推定が LSTM-based LQE において正解を正解として捉える性能が高いことを示している。

一方、図 4 から、SAE-LQE は Accuracy がクラス 1(非常に悪い), クラス 3(普通)で 80% 以上で、Recall はクラス 2(悪い), クラス 5(非常に良い)で 80% 以上であった。LSTM-based LQE は、SAE-LQE と比較して、Accuracy では 4つのクラスで、Recall においても 4つのクラスで高い性能を示しており、提案手法の有効性を確認した。

5. おわりに

本論文では、我々はシーケンシャルな情報を活用できる LSTM ベースの WLQE モデルを開発した。実際の移動体通信デバイスによるデータセットを用いてベースラインモデルと比較評価を行い、提案手法の方が高精度に推定が可能であることを示した。LSTM で RSRP の値を推定するモデルの有効性を示した本結果は、リンク品質推定においてリンク品質の時間相関的な情




図 3 LSTM-based LQE における各クラスの Accuracy と Recall

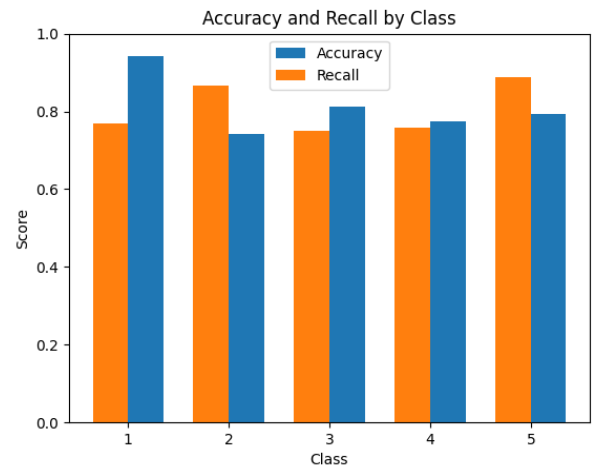


図 4 SAE-LQE における各クラスの Accuracy と Recall

報を利用すること重要性を示している。

また、実環境での移動体通信デバイスにより計測された通信メトリクスのデータセットを用いて、訓練と予測を行い、我々の提案手法の実環境への有効性を確認した。本論文の実験結果から LSTM-based LQE には、いくつかの有望な展望があると考えられる。LSTM-based LQE は、ワイヤレスネットワークを利用する移動体通信デバイスに対して、最適なリンク経路を選択するための重要な情報の提供を行ったり、アプリケーションではデータのバッファリング処理を割り込ませたりすることが可能になる。

今後は、本論文では用いなかった通信メトリクスなどの特徴量を用いることや、離散化の手法、ハイパーパラメータの設定の値などのチューニングを行うことで、さらに高精度な推定が可能になると考えられる。複数の環境のデータセットで性能比較することでモデルの異なる環境への適応性評価や新たな評価指標の導入、実環境でのエッジデバイス運用による性能評価などが今後の課題である。

謝辞 本研究の一部は、JSPS 科研費 JP23H03379 の助成を受けたものである。

文 献

- [1] G. Cerar, H. Yetgin, M. Mohorčič, and C. Fortuna, "Machine Learning for Wireless Link Quality Estimation: A Survey," *IEEE Communications Surveys & Tutorials*, vol.23, no.2, pp.696–728, 2021.
- [2] X. Luo, L. Liu, J. Shu, and M. Al-Kali, "Link Quality Estimation Method for Wireless Sensor Networks Based on Stacked Autoencoder," *IEEE Access*, vol.7, pp.21572–21583, 2019.
- [3] G.T. Nguyen, R.H. Katz, B. Noble, and M. Satyanarayanan, "A trace-based approach for modeling wireless channel behavior," *Proceedings Winter Simulation Conference (WSC 1996)*, pp.597–604, ACM, Nov. 1996.
- [4] S. Farthofer, M. Herlich, C. Maier, S. Pochaba, J. Lackner, and P. Dorfinger, "CRAWDAD srfg/lte-4g-highway-drive-tests-salzburg," 2022. <https://dx.doi.org/10.15783/6gc4-y070>
- [5] H. Balakrishnan, R. Katz, et al., "Explicit Loss Notification and Wireless Web Performance," *Proceedings of the IEEE Global Communications Conference (GLOBECOM 1998) Internet Mini-Conference*, vol.98, IEEE, Nov. 1998.
- [6] A. Woo, T. Tong, and D. Culler, "Taming the Underlying Challenges of Reliable Multihop Routing in Sensor Networks," *Proceedings of the 1st International Conference on Embedded Networked Sensor Systems (SenSys 2003)*, pp.14–27, ACM, Nov. 2003.
- [7] M.J.P.L. Kannan Srinivasan, Maria A. Kazandjieva, "PRR Is Not Enough," 2008. <http://sing.stanford.edu/pubs/sing-08-01.pdf>
- [8] R. Fonseca, O. Gnawali, K. Jamieson, and P. Levis, "Four Bit Wireless Link Estimation," *Proceedings of the 6th Workshop on Hot Topics in Networks (HotNets 2007)*, ACM, Oct. 2007.
- [9] C.A. Boano, M.A. Zúñiga, T. Voigt, A. Willig, and K. Römer, "The Triangle Metric: Fast Link Quality Estimation for Mobile Wireless Sensor Networks," *Proceedings of the 19th International Conference on Computer Communications and Networks (ICCCN 2010)*, IEEE, Aug. 2010.
- [10] M.H. Henry-Joseph Audéoud, "Quick and Efficient Link Quality Estimation in Wireless Sensors Networks," *Proceedings of the 14th Annual Conference on Wireless On-demand Network Systems and Services (WONS 2018)*, pp.87–90, IEEE, Feb. 2018.
- [11] B. Nouha, K. Anis, Y. Habib, M.B. Jamâa, D. doRosário, A. Mário, and L.B. Becker, "F-LQE: A Fuzzy Link Quality Estimator for Wireless Sensor Networks," *Proceedings of the 7th European Conference on Wireless Sensor Networks (EWSN 2010)*, vol.5970, pp.240–255, Springer, Feb. 2010.
- [12] Z.-Q. Guo, Q. Wang, M.-H. Li, and J. He, "Fuzzy Logic Based Multi-dimensional Link Quality Estimation for Multi-Hop Wireless Sensor Networks," *IEEE Sensors Journal*, vol.13, no.10, pp.3605–3615, July 2013.
- [13] S. Rekik, N. Baccour, M. Jmaiel, and K. Drira, "Low-Power Link Quality Estimation in Smart Grid Environments," *Proceedings of the International Wireless Communications and Mobile Computing Conference (IWCMC 2015)*, pp.1211–1216, IEEE, Aug. 2015.
- [14] N. Baccour, A. Koubâa, M.B. Jamâa, D. Do Rosario, H. Youssef, M. Alves, and L.B. Becker, "Radiale: A Framework for Designing and Assessing Link Quality Estimators in Wireless Sensor Networks," *Ad Hoc Networks*, vol.9, no.7, pp.1165–1185, Sept. 2011.
- [15] T. Liu and A.E. Cerpa, "Foresee (4C): Wireless Link Prediction Using Link Features," *Proceedings of the 10th ACM/IEEE International Conference on Information Processing in Sensor Networks (IPSN 2011)*, pp.294–305, IEEE, April 2011.
- [16] S. Demetri, M. Zúñiga, G.P. Picco, F. Kuipers, L. Bruzzone, and T. Telkamp, "Automated Estimation of Link Quality for LoRa: A Remote Sensing Approach," *Proceedings of the 18th International Conference on Information Processing in Sensor Networks (IPSN 2019)*, pp.145–156, IEEE, April 2019.
- [17] T. Liu and A.E. Cerpa, "Temporal Adaptive Link Quality Prediction with Online Learning," *ACM Transactions on Sensor Networks*, vol.10, no.3, May 2014.
- [18] T. Liu and A.E. Cerpa, "TALENT: Temporal Adaptive Link Estimator with No Training," *Proceedings of the 10th ACM Conference on Embedded Network Sensor Systems (SenSys 2012)*, pp.253–266, ACM, Nov. 2012.
- [19] G. Cerar, H. Yetgin, M. Mohorčič, and C. Fortuna, "On Designing a Machine Learning Based Wireless Link Quality Classifier," *Proceeding of the IEEE 31st Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC 2020)*, IEEE, Aug. 2020.
- [20] P. Millan, C. Molina, E. Medina, D. Vega, R. Meseguer, B. Braem, and C. Blondia, "Time Series Analysis to Predict Link Quality of Wireless Community Networks," *Computer Networks*, vol.93, pp.342–358, Dec. 2015.
- [21] H. Okamoto, T. Nishio, M. Morikura, K. Yamamoto, D. Murayama, and K. Nakahira, "Machine-Learning-Based Throughput Estimation Using Images for mmWave Communications," *Proceeding of the 85th IEEE Conference on Vehicular Technology (VTC 2017)*, IEEE, June 2017.
- [22] M.L. Bote-Lorenzo, E. Gómez-Sánchez, C. Mediavilla-Pastor, and J.I. Asensio-Pérez, "Online Machine Learning Algorithms to Predict Link Quality in Community Wireless Mesh Networks," *Computer Networks*, vol.132, pp.68–80, Jan. 2018.
- [23] J. Shu, S. Liu, L. Liu, L. Zhan, and G. Hu, "Research on Link Quality Estimation Mechanism for Wireless Sensor Networks Based on Support Vector Machine," *Chinese Journal of Electronics*, vol.26, no.2, pp.377–384, March 2017.
- [24] W. Rehan, S. Fischer, and M. Rehan, "Machine-Learning Based Channel Quality and Stability Estimation for Stream-Based Multichannel Wireless Sensor Networks," *Sensors*, vol.16, no.9, p.1476, Sept. 2016.
- [25] E. Ancillotti, C. Vallati, R. Bruno, and E. Mingozzi, "A Reinforcement Learning-based Link Quality Estimation Strategy for RPL and its Impact on Topology Management," *Computer Communications*, vol.112, pp.1–13, Nov. 2017.
- [26] W. Sun, W. Lu, Q. Li, L. Chen, D. Mu, and X. Yuan, "WNN-LQE: Wavelet-Neural-Network-Based Link Quality Estimation for Smart Grid WSNs," *IEEE Access*, vol.5, pp.12788–12797, July 2017.
- [27] "MiFi Signal Strength Bar Meaning (RSRP,SNR,RSSI)". <https://insg.my.site.com/insgtechsupport/s/article/MiFi-Signal-Strength-Bars-vs-RSRP-etc>