

LSTMモデルを用いた 無線リンク品質推定

† 長岡技術科学大学 大学院工学研究科
関東悠樹† 渡部康平†

目次

1. 目的・背景
2. 先行研究
3. 提案法
4. 実験
5. まとめ・今後の展望

目的・背景

目的・背景

- ◆近年、移動通信デバイスは屋内外で通信環境が変動し、**安定性と信頼性**のあるネットワーク接続が望まれている
- ◆移動通信デバイスに**未来の通信品質を提供**することで、通信が不安定になる前にバッファリングや最適なリンクへの切り替えを行う事を可能になる
- ◆従来法の通信品質の推定では、静的環境で行われ**移動環境の変化に柔軟に対応できない**という問題



目的・背景

◆目的

シーケンシャルな情報を活用して、未来の通信品質を高精度に推定する




品質が悪化または改善？

◆提案手法による貢献

通信品質の悪化を予測し、通信品質情報の提供を実現する
従来より移動環境に強いモデルを提供する

山間部などで通信不安定に



本手法で高精度に通信品質を推定
ユーザは安定してアプリケーションを利用

先行研究

リンク品質について

◆リンク品質とは、通信メトリクスを用いてネットワークの状態や品質を評価する指標のことである。

◆通信メトリクスについて

1. RSRP [dBm]: 基地局からのリファレンス信号の受信電力を表す。値が大きいほど**受信電力**が強いことを示す。
2. SINR [dB]: 受信信号と干渉信号およびノイズの比を表す。値が大きいほど受信信号の**品質**が高いことを示す。

◆ 5段階のリンク品質のグレード化[1]

Table 1 リンク品質グレード定義


RSRP[dBm]	リンク品質グレード
$-84 \leq$	非常に良い
$-84 < \text{RSRP} < -95$	良い
$-95 < \text{RSRP} < -105$	普通
$-105 < \text{RSRP} < -115$	悪い
$\text{RSRP} \leq -115$	非常に悪い

先行研究：LQE-SAEモデル

◆先行研究の中で最も推定精度が優れている機械学習手法の一つ[2]

◆LQE-SAEモデル[3]

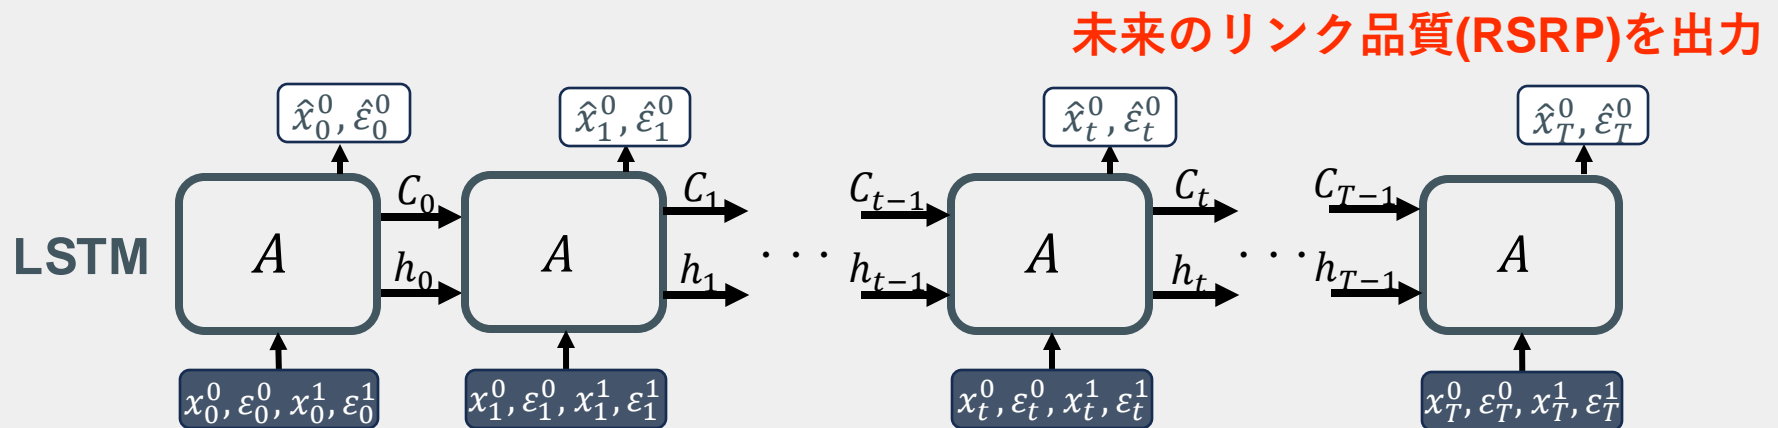
1. Auto Encoder(AE)を積層にしたStacked-AEを主軸とした、リンク品質推定モデル
2. 最終的な特徴抽出ベクトルをSupport Vector Classification (SVC)に入力し、未来のリンク品質の分類推定を行い、**未来の5段階のリンク品質グレード**を出力する



提案手法

シーケンシャルなLQEモデルの提案

- ◆LSTM (Long Short-Term Memory)は、長期的な依存関係を学習可能であり、時系列データに対してよく用いられる手法
- ◆通信メトリクス情報の時系列データに着目し、**未来のリンク品質(RSRP)**を推定
- ◆通信メトリクスのデータから**平滑化データ(トレンド成分)**、**残差成分**に加工し、これらの**時系列情報を**基にLSTMで学習



各通信メトリクスのトレンド、残差成分を入力

表記について

◆実測値データ： src^j

j番目の特徴量のシーケンス（0:RSRP, 1:SINR）

◆説明変数


j番目の特徴量のシーケンスにおける時刻tの要素

- ・トレンド成分： x_t^j
- ・残差成分： ε_t^j

◆目的変数

RSRP(j=0)におけるトレンド及び残差成分を出力

- ・トレンド： \hat{x}_T^0
- ・残差成分： $\hat{\varepsilon}_T^0$



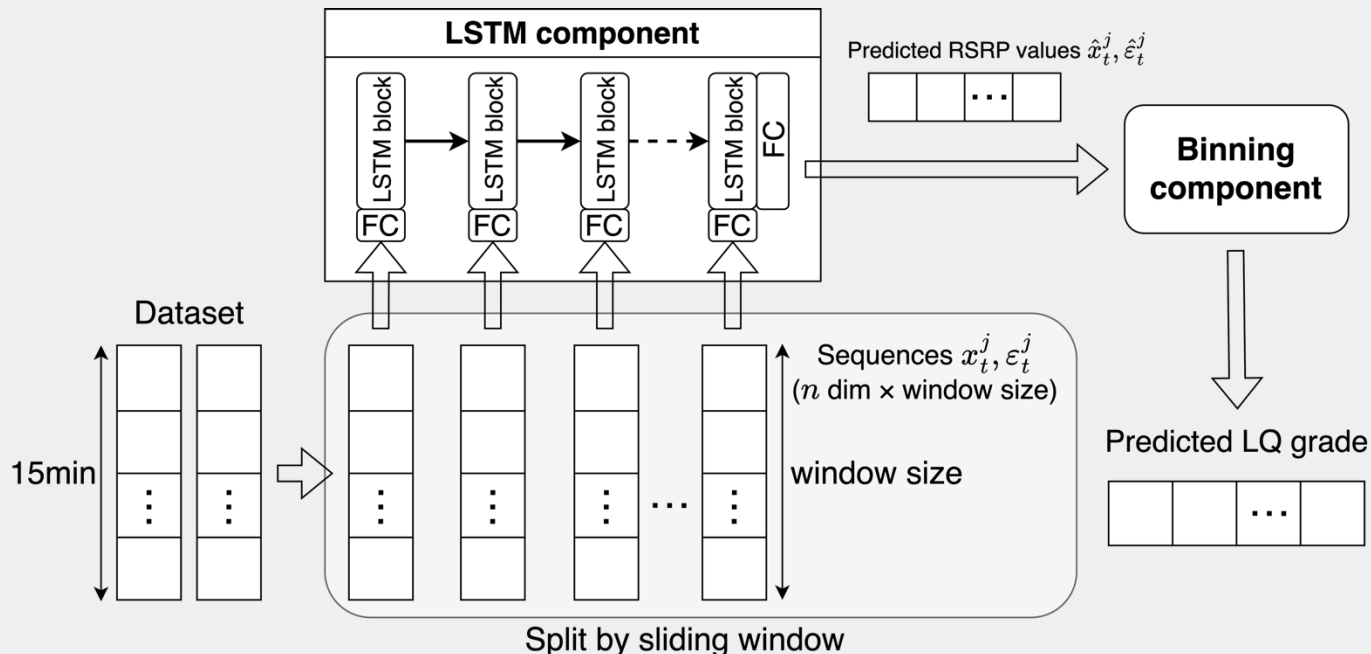
合算処理

RSRPの予測値


提案手法：LSTM-based LQE

◆提案モデル

1. アーキテクチャ内のLSTMは回帰モデルであるが、出力値を**ビンニング処理**に通し離散値として扱い、分類モデルとして評価
2. ビンニングとは、**連続値を任意の境界値で区切り離散化**する変換処理のことである。
3. 入力シーケンスのwindow sizeとは、約15分のトレースデータをある一定の長さで分割する際のデータの長さである



前処理（１）




◆補間処理


- ◆データセットに含まれる欠損部分に対して、ゼロで強制的に補間を行うZero-Paddingを採用[2]

◆部分時系列の作成

- ◆1トレースの長いデータは計測時間が不揃いで全体のトレース数も限られている
- ◆window sizeを指定して、部分時系列として切り出すことで、**一本の時系列から多数の時系列を作成**し固定データ長に加工



前処理（２）



◆特徴量エンジニアリング（各通信メトリクスに対して）

◆RSRPなどの通信メトリクスは大きな変動性とノイズがあるため、学習行いやすいよう、平滑化を行なっている。

- **トレンド成分**：指数平滑移動平均（Exponential Moving Average: EMA）によって平滑化

$$x_0^j = src_0^j$$


$$x_t^j = \alpha \cdot src_t^j + (1 - \alpha)x_{t-1}^j$$

$$\text{平滑化係数 } \alpha = \frac{2}{span+1.0}$$

- **残差成分**：実測値とEMAの差分

$$\varepsilon_t^j = src_t^j - x_t^j$$

前処理（3）



◆標準化処理（Z-score normalization）

- ◆入力特徴量内のスケールを合わせるため訓練データを基に標準化を行っている
- ◆平均 0，分散 1 にスケーリング

実験

実験手順

- ◆SRFGデータセットを用いて提案モデル及び先行モデルを学習
- ◆データセットは訓練，検証，テストで7:2:1に分割
- ◆提案モデルは，まずLSTMで学習を行いEarly Stoppingを用いて検証のlossが増加する前の最良モデルを用意
- ◆LSTMモデルで推定した出力値をビンングコンポーネントに入力し，離散化処理を行う
- ◆最終的に，学習済のLSTMモデルを用いてテストデータセット評価

データセット

◆LTE-4G-HIGHWAY-DRIVE-TESTS-SALZBURG (SRFG-Dataset)

◆概要

- 測定環境: 車(高速道路)
- 測定距離: 25km/セッション
- 測定期間: 2年間 (2018-2019)
- データ数: 267,198 点

◆通信メトリクス

- タイムスタンプ
- GPS
- 信号品質
 - Signal bars
 - RSSI
 - **SINR**
 - **RSRP**
 - RSRQ

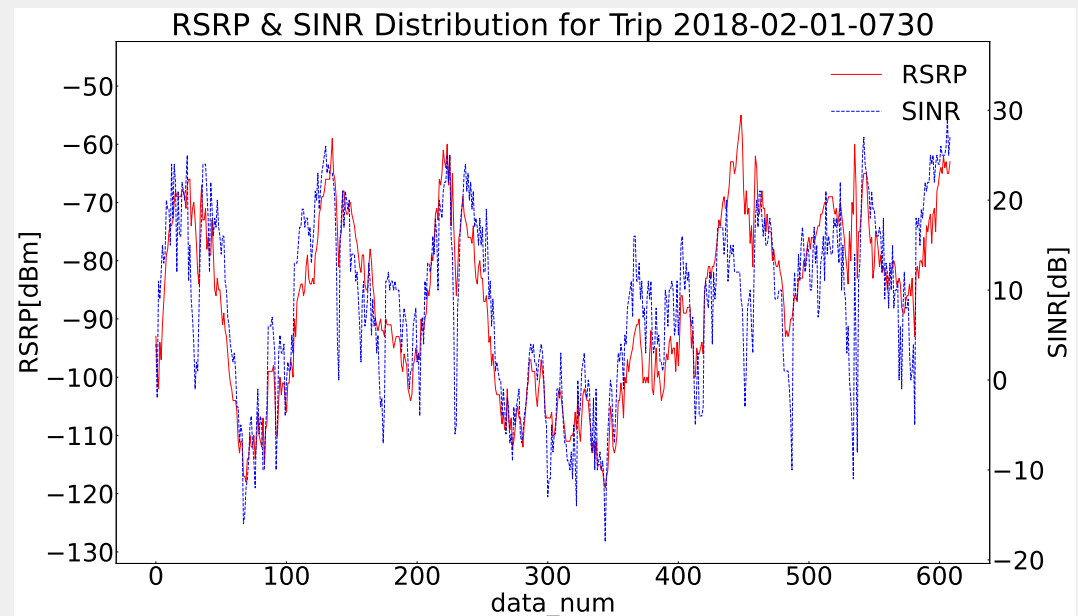


Fig.1 Trip Data

ハイパーパラメータ

◆提案モデル：LSTMパラメータ

エポック数	1000	
学習率	0.001	
バッチサイズ	128	
層数	2	
最適化関数	Adam	
dropout	0.266309509	
隠れ層サイズ	128	
Sliding window	370	
EMA span	120	
Early Stopping	patience	50
	delta	-0.0001

◆ LQE-SAEモデル

◆論文準拠

評価手法（１）

◆リンク品質分類モデルの評価について[4]

◆Accuracy（正解率）

- ・ 予測したクラスと真のクラスと一致した数を全体のデータ数との割合を示す.

◆Recall（再現率）

- ・ 真のPositiveのうち正しく予測できた割合を示す.

◆Precision（適合率）

- ・ Positiveと予測したクラスのうち、実際にPositiveだったものの割合を示す.

評価手法（２）

◆リンク品質分類モデルの評価について[4]

◆macro F1-Score

- ・ クラス毎のF1-scoreを平均した値. F1-scoreは適合率と再現率の調和平均である.

◆Confusion matrix（混同行列）

- ・ モデルが予測したクラスと正解ラベルが一致する数が多いと、行列の対角成分の値が大きくなる. また誤ったクラスのばらつきの傾向を観察.

実験結果（クラス別 Recall&Accuracy）

- ◆Accuracyでは，ベースラインモデルと比較して提案モデルの方が3つの品質グレードで向上を確認
- ◆Recallについては，提案モデルの方が4つの品質グレードで向上




Fig.2 Test dataset (LQE-SAE)




Fig.3 Test dataset (LSTM-based LQE)

実験結果（混同行列）

- ◆ベースラインモデルと比較して提案手法の方が、対角成分で**3つのリンク品質グレードで精度が向上**
- ◆提案モデルでは誤ったクラスのばらつきが抑えられ、ベースラインモデルと比較して、より正解に近い品質グレードを予測できている




Fig.4 Test dataset (LQE-SAE)




Fig.5 Test dataset (LSTM-based LQE)

実験結果（F1値 & Accuracy）

◆各モデルの性能評価

◆提案モデルは、ベースラインモデルと比較して平均Accuracyは**11.2%**，macro F1で**5.92%向上**

◆これらの評価指標を通して、ベースラインモデルより性能が向上していることを確認

Table 2 Model Performance

Model	平均Accuracy	macro-F1
SAE-LQE	0.773	0.520
LSTM-based LQE	0.885	0.579

まとめ

まとめ・今後の展望

◆まとめ

- ◆シーケンシャルな情報を活用する本提案法は、高精度にリンク品質推定を行う上で有効であることを示した
- ◆現状、一部の特微量や小規模データセットで学習を行っている
 - ◆位置情報や他のメトリクスを最大限に活用できていない

◆今後の展望

- ◆最適なハイパーパラメータの探索
- ◆他特微量を活用した、新たな手法の提案
- ◆大規模データセットによるモデルの適応性の評価
- ◆品質グレードに依存しない、回帰モデルによるリンク品質推定モデルの検討
- ◆新たなモデル評価方法の検討

参考文献

- [1] “MiFi Signal Strength Bar Meaning (RSRP,SNR,RSSI)”. [https://insg.my.site.com/insgtechsupport/s/article/MiFi-Signal-Strength-Bars- vs-RSRP-etc](https://insg.my.site.com/insgtechsupport/s/article/MiFi-Signal-Strength-Bars-vs-RSRP-etc)
- [2] Gregor Cerar and Halil Yetgin and Mihael Mohorcic and Carolina Fortuna, "Machine Learning for Wireless Link Quality Estimation: A Survey", IEEE Communications Surveys, vol23, No.2, pp. 696--728
- [3] X. Luo, L. Liu, J. Shu, and M. Al-Kali, "Link quality estimation method for wireless sensor networks based on stacked autoencoder", IEEE Access, vol. 7, 2019, pp. 21572–21583,
- [4] 高柳慎一, 長田怜士, "評価指標入門", 技術評論社, 2023

発表文献

- ◆ Y. Kanto and K. Watabe, "Wireless Link Quality Estimation Using LSTM Model," 2024 IEEE Network Operations and Management Symposium (NOMS 2024), Seoul, Korea, 2024, pp. 1-4.

ご清聴ありがとうございました

資料

◆SAE-LQEのハイパーパラメータ

- ◆学習率: 0.001
- ◆Epoch: 20
- ◆Batch size: 128
- ◆Activation function: Softplus
- ◆Hidden layer(SAE1~2): 6
- ◆Hidden layer(SAE3): 1 or 2

◆メトリクス

- ◆RSRP (Reference Signal Received Power) : 基地局からのリファレンス信号の受信電力を表します。単位はdBmで、値が大きいくほど受信電力が強いことを示します。
- ◆SINR (Signal to Interference plus Noise Ratio) : 受信信号と干渉信号およびノイズの比を表します。単位はdBで、値が大きいくほど受信信号の品質が高いことを示します。
- ◆RSSI (Received Signal Strength Indicator) : 受信信号の強度を表します。単位はdBmで、値が大きいくほど受信信号の強度が高いことを示します。

RSSI [dBm]について

◆RSSI (Received Signal Strength Indicator)

- ◆受信信号強度を表しており，ワイヤレス接続に十分な信号があるかどうかを判断できる値


◆単位dBmについて

- ◆受信信号電力[mW]を，1mWを基準に対数表示した値

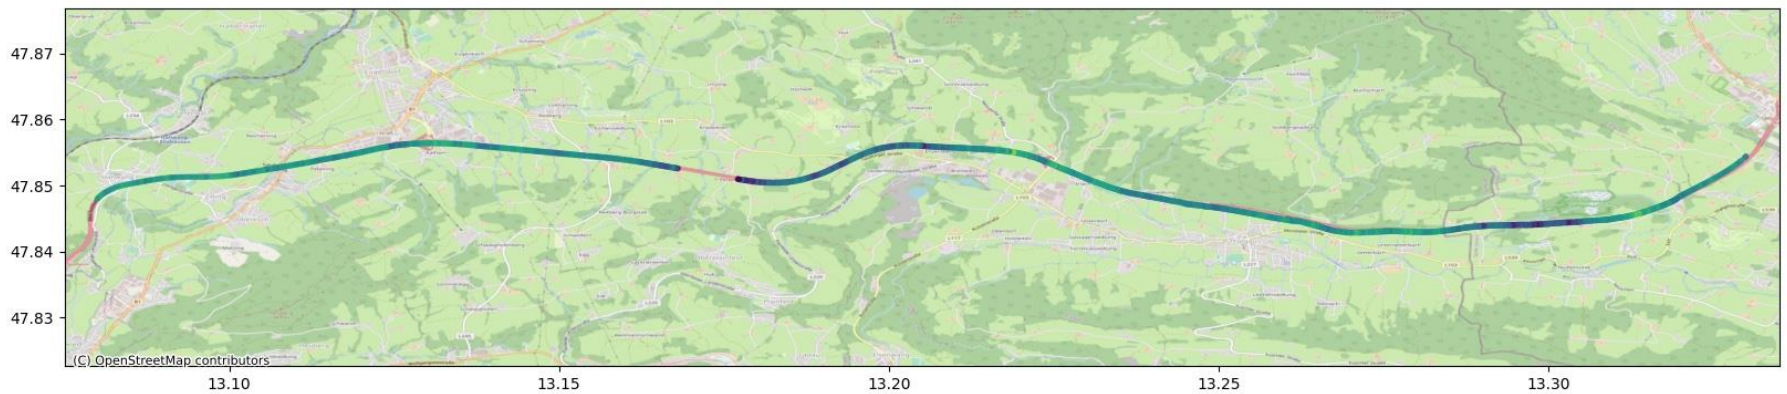
$$dBm = 10 \times \log_{10}(\text{受信信号電力})$$

- ◆受信電力1mWの時 → 0dBm (理想的な良好リンク)
- ◆ “ $1 \times 10^{-9}mW$ の時 → -90dBm (不良リンク)

データセット：トレースデータ例



Case1



Case2

Ofcom

◆オープンデータ

◆現在は4G /LTE 2021版を調査

Data	Last updated
4G LTE mobile signal strength measurement data (2020) 	23 November 2021
4G LTE mobile signal strength measurement data (2021) 	30 April 2022
4G LTE mobile signal strength measurement data (2022) 	3 March 2023
5G NR mobile signal strength measurement data (2020) 	23 November 2021
5G NR mobile signal strength measurement data (December 2020 to May 2021) 	23 November 2021
5G NR mobile signal strength measurement data (June 2021 to September 2021) 	30 April 2022
5G NR mobile signal strength measurement data (October 2021 to December 2021) 	30 April 2022
5G NR mobile signal strength measurement data (January 2022 to April 2022) 	30 April 2022
5G NR mobile signal strength measurement data (May 2022 to September 2022) 	3 March 2023
5G NR mobile signal strength measurement data (October 2022 to December 2022) 	3 March 2023

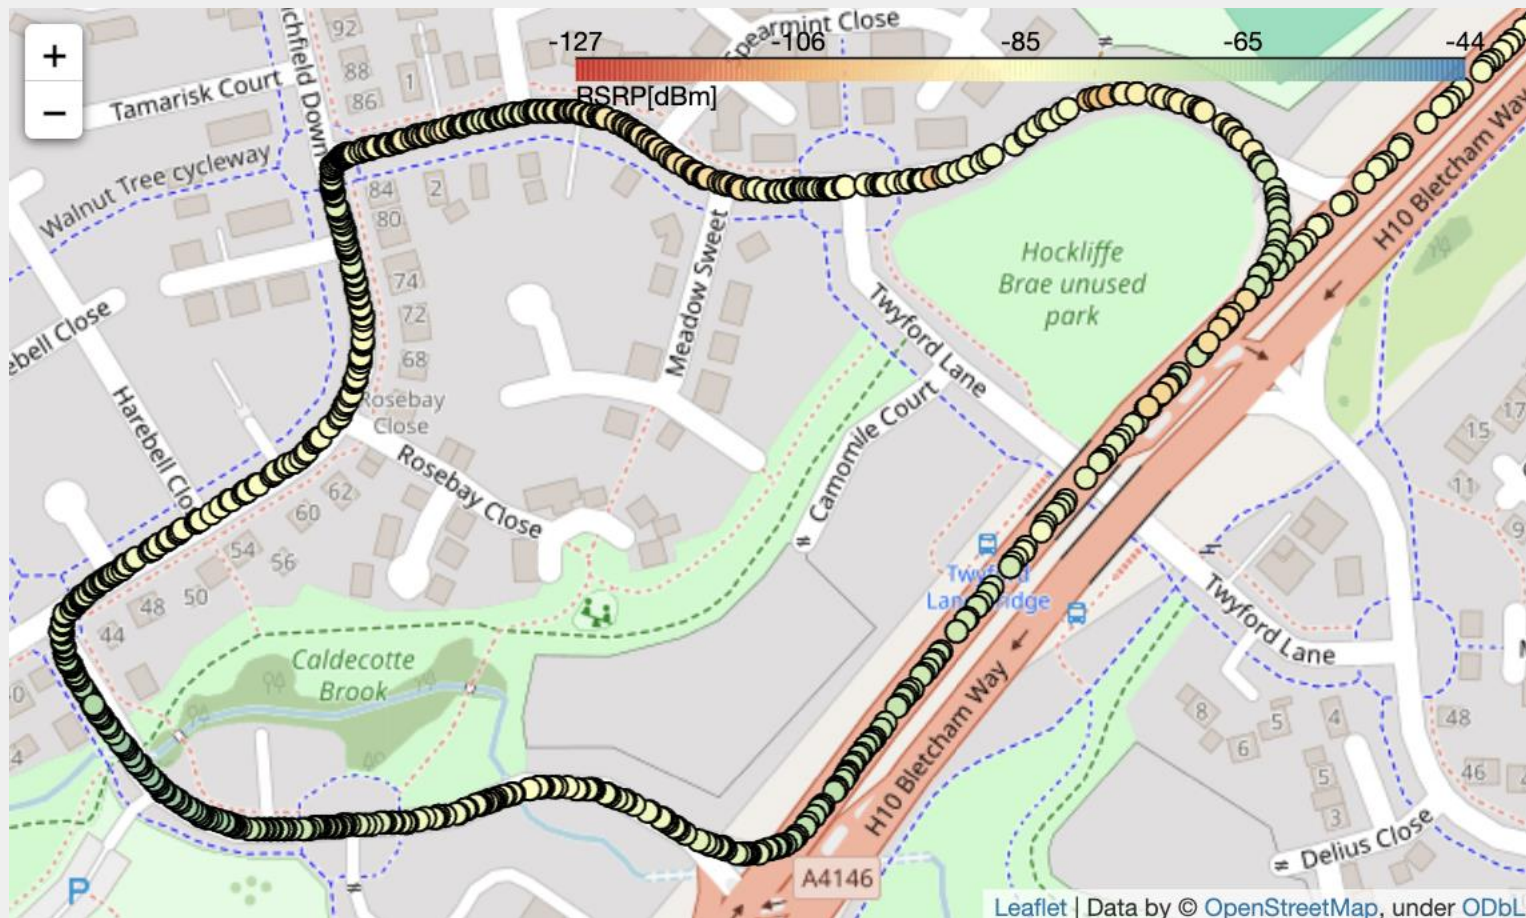
Ofcomデータセット

- ◆電波測定車両による定期的なモバイルドライブテストの測定データが英国のOfcom(英国情報通信庁)からオープンデータセットで公開
- ◆英国全土の道路沿いで収集した 4G および 5G 固有の信号強度測定データの収集
- ◆4Gデータセット (3年分: 1.5億ポイント分)
- ◆4G parameters
 - ◆GPS
 - ◆RSSI
 - ◆SINR
 - ◆RSRP
 - ◆RSRQ etc.



Ofcomデータセットの一部表示 (RSRP)

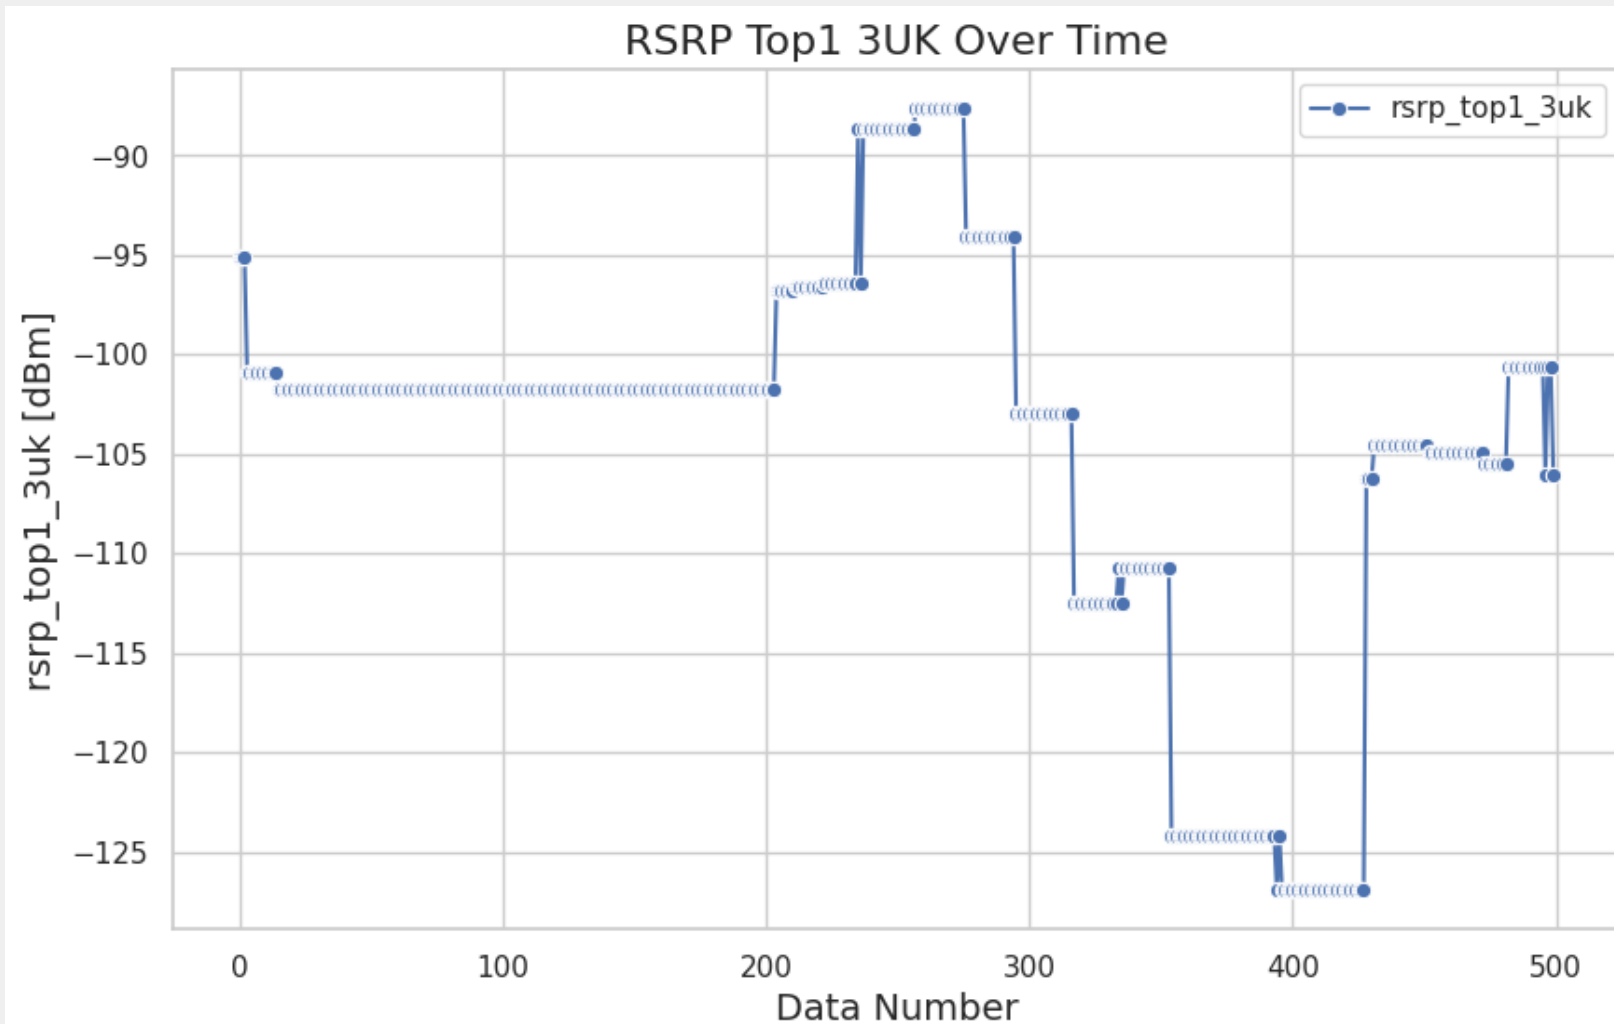
◆RSRPの強度に合わせて、プロットの色を変化させた。



Leaflet | Data by © OpenStreetMap, under ODbL



Ofcomデータセットの一部表示 (RSRP)

◆RSRPの500ポイント時系列変化




Dropout



- ◆一度学習した**ネットワークの一部を忘れる学習法**のひとつ
- ◆ニューラルネットワーク中の重みの一部をランダムに強制的に0にリセット
- ◆一度学習させた内容を一部をあえて忘れ、再度学習し繰り返す
- ◆Dropoutによって**局所的最適解に落ちることを防ぐ**ことが可能に



ベースラインモデル



提案モデル



macro F1
LSTM 57.87%
LQE-SAE 51.95%
+5.92%

Accuracy
LSTM 88.5%
LQE-SAE 77.3%
+11.2%